## Devoir2-Exo1

May 3, 2023

```
[271]:  # Pour visualiser les données j'utilise la bibliothèque Pandas étudiée en⊔

→ DataScience -1

# Importation des librairies nécessaires

import pandas as pd
```

# 1 1) Ouverture du fichier

```
[218]: # Importation des données
      vente_pneus = pd.read_csv('vente_pneus.csv', sep = ';')
[219]: vente_pneus.head()
[219]:
        Unnamed: 0 2017 2018 2019
                                     2020
                                           2021
                                                 2022
                    8.0
                          9.0 10.0 12.0
                                           16.0
                                                  9.0
                 2 10.0 11.0 12.0 14.0
                                           18.0 11.0
                 3 12.0 13.0 14.0 16.0
                                           20.0
                                                 13.0
                 4 19.0 20.0 20.0 23.0
                                           27.0 19.0
                 5 23.0 22.0 22.0 27.0 31.0 21.0
[220]: print(vente_pneus.dtypes)
      Unnamed: 0
                    object
      2017
                   float64
      2018
                   float64
      2019
                   float64
      2020
                   float64
      2021
                   float64
      2022
                   float64
      dtype: object
[221]: vente_pneus.shape
[221]: (54, 7)
[222]: # Renommer la colonne 'colonne1' en 'nouvelle_colonne'
      vente_pneus = vente_pneus.rename(columns={'Unnamed: 0': 'numero semaine'})
```

```
[223]: vente_pneus.head()
                           2017
[223]:
                                  2018
                                        2019
                                               2020
                                                      2021
                                                             2022
         numero semaine
       0
                            8.0
                                   9.0
                                         10.0
                                               12.0
                                                      16.0
                                                              9.0
                           10.0
       1
                        2
                                  11.0
                                        12.0
                                               14.0
                                                      18.0
                                                             11.0
       2
                        3
                           12.0
                                  13.0
                                        14.0
                                               16.0
                                                      20.0
                                                             13.0
       3
                           19.0
                                  20.0
                                        20.0
                                               23.0
                                                      27.0
                                                            19.0
       4
                        5
                           23.0
                                  22.0
                                        22.0
                                               27.0
                                                      31.0
                                                            21.0
```

Au vu des données il s'agit de vente de pneu par année et par semaine dans une année (il y en a bien 52). A quoi corresponds Somme?.

```
[224]: vente_pneus['2021'].sum()
```

[224]: 2893.0

Il s'agit donc d'inférer la valeur des ventes la 52ème semaine

Somme semble correspondre approximativement à la moitié de la somme des éléments dans une colonne (sans prendre en compte les valeurs manquantes représentée dans pandas en NaN.

Et si je représentai les courbes pneus vendu par semaine?

#### 1.1 3) Représentation des données

```
[225]: # Suppression des NaN
       vente_pneus = vente_pneus.dropna()
[226]:
      vente_pneus.head()
[226]:
                                       2019
                                              2020
                                                    2021
         numero semaine
                          2017
                                 2018
                                                           2022
                           8.0
                                  9.0
                                       10.0
                                              12.0
                                                    16.0
                                                            9.0
       0
                       1
       1
                       2
                          10.0
                                 11.0
                                       12.0
                                              14.0
                                                    18.0
                                                           11.0
                       3
       2
                          12.0
                                 13.0
                                       14.0
                                              16.0
                                                    20.0
                                                           13.0
                       4
                                       20.0
                                                    27.0
       3
                          19.0
                                 20.0
                                              23.0
                                                           19.0
       4
                       5
                          23.0
                                 22.0
                                       22.0
                                              27.0
                                                    31.0
                                                           21.0
[227]: # Suppression de l'index 53 (somme)
       vente_pneus.drop(53, axis=0, inplace=True)
[228]: |vente_pneus['numero semaine']=vente_pneus['numero semaine'].astype(float,_
         ⇔errors = 'raise')
[229]:
       vente_pneus.head()
[229]:
          numero semaine
                           2017
                                  2018
                                        2019
                                               2020
                                                     2021
                                                            2022
       0
                      1.0
                            8.0
                                   9.0
                                        10.0
                                               12.0
                                                     16.0
                                                             9.0
       1
                           10.0
                                  11.0
                                        12.0
                                               14.0
                                                     18.0
                      2.0
                                                           11.0
```


```
2
                    12.0
                          13.0
                                 14.0
                                       16.0
                                             20.0
                                                    13.0
3
                    19.0
                          20.0
                                 20.0
                                       23.0
                                             27.0
                                                   19.0
                                       27.0
                    23.0
                          22.0
                                22.0
                                             31.0
                                                    21.0
```

```
[230]: import matplotlib.pyplot as plt
```

Essayons de représenter les données

```
[231]: vente_pneus.plot()
```

#### [231]: <AxesSubplot:>




On observe une forme récurrente, cette représentation n'est pas trés pratique, une autre forme de representation consiste à représenter les données comme un nuage de points.

Représentons ces données

```
[234]: import numpy as np
    listOf_Xticks = np.arange(0, 55, 5)
    plt.xticks(listOf_Xticks)
    plt.scatter(x_raw,y_raw,marker='+')
```

[234]: <matplotlib.collections.PathCollection at 0x7f95fed57c10>




### 1.2 4) Préparation des données

Les données sont assez corrélées, ce qui est normal les ventes sont fonction de la semaine dans l'année maintenant il peut y avoir des années avec des valeurs extrèmes des outliers comme on les nomment. Allons plus loin dans l'étude de la corrélation.

```
[235]: # Analyse de la corrélation
import seaborn as sns
plt.figure(figsize=(8, 6))
sns.heatmap(vente_pneus.corr(), annot=True, cmap='coolwarm', fmt='.2g')
```

[235]: <AxesSubplot:>




On voit que 2017 et 2018 suivent le même schéma avec une corrélation à 0.9.L'année 2021 est la moins corrélée avec les autres années on peut se dire que c'est liée à la période du covid, cette année est en quelque sorte "spéciale". Si l'on choisit de ne conserver comme données d'entrée pour notre modèle que la moyenne en 'sortant' des valeurs inappropriées c'est à dire l'année 2021 on obtient:

```
[236]: moy=1/
         5*(vente_pneus['2017']+vente_pneus['2018']+vente_pneus['2019']+vente_pneus['2020']+vente_pneus['2020']
       vente_pneus['moy']=moy
[237]:
[238]:
       vente_pneus.head()
[238]:
          numero semaine
                            2017
                                  2018
                                         2019
                                               2020
                                                      2021
                                                             2022
                                                                    moy
       0
                      1.0
                             8.0
                                   9.0
                                         10.0
                                               12.0
                                                      16.0
                                                              9.0
                                                                    9.6
                                         12.0
       1
                      2.0
                            10.0
                                  11.0
                                                14.0
                                                      18.0
                                                                   11.6
                                                            11.0
       2
                      3.0
                            12.0
                                  13.0
                                         14.0
                                                16.0
                                                      20.0
                                                             13.0
                                                                   13.6
       3
                      4.0
                            19.0
                                  20.0
                                         20.0
                                                23.0
                                                      27.0
                                                             19.0
                                                                   20.2
       4
                      5.0
                            23.0
                                  22.0
                                         22.0
                                               27.0
                                                      31.0
                                                            21.0
                                                                   23.0
```

```
[239]: import numpy as np
    listOf_Xticks = np.arange(0, 55, 5)
    plt.xticks(listOf_Xticks)
    plt.scatter(vente_pneus['numero semaine'], vente_pneus['moy'], marker='+')
```


[239]: <matplotlib.collections.PathCollection at 0x7f95ff35ad90>



### 1.3 5) Normalisation des données

La normalisation des données permet d'augmenter la rapidité de la convergence du réseau de neurones

[243]: <matplotlib.collections.PathCollection at 0x7f95fdbcfca0>



### 1.4 5) Choix du modèle

Importons d'abord les librairies requises:

```
[244]: import tensorflow.compat.v1 as tf
    tf.disable_v2_behavior()
    from tensorflow.python.keras import layers
    from tensorflow.python.keras.layers import Activation,Dense
    import matplotlib.pyplot as plt
```

Le modèle est constitué d'une couche d'entrée (Input) avec une dimension de 1, suivie de deux couches cachées (Dense) avec 15 et 10 neurones respectivement, et une couche de sortie (Dense) avec une sortie de dimension 1.

La fonction d'activation utilisée pour toutes les couches est la fonction sigmoid. Le modèle est compilé avec l'optimiseur de descente de gradient stochastique (SGD) avec un taux d'apprentissage de 0,25 et la fonction de perte MSE (Mean Squared Error).

Il est ensuite entraîné sur les données vente\_pneus['numero\_semaine\_norm'] et vente\_pneus['moy\_norm'] avec un nombre d'époques de 30000 et une taille de batch de 17.

```
[245]: inputs = tf.keras.Input(shape=(1,))
h1 = tf.keras.layers.Dense(15,activation=tf.sigmoid)(inputs)
h2 = tf.keras.layers.Dense(10,activation=tf.sigmoid)(h1)
outputs = tf.keras.layers.Dense(1,activation=tf.sigmoid)(h2)
mon_model = tf.keras.Model(inputs=inputs,outputs=outputs)
mon_model.summary()
```

Model: "model\_6"

Layer (type)	Output Shape	Param #
input_7 (InputLayer)	[(None, 1)]	0
dense_18 (Dense)	(None, 15)	30
dense_19 (Dense)	(None, 10)	160
dense_20 (Dense)	(None, 1)	11

\_\_\_\_\_\_

Total params: 201 Trainable params: 201 Non-trainable params: 0

\_\_\_\_\_\_

2023-05-03 19:28:57.286746: W tensorflow/c/c\_api.cc:300] Operation

#### 1.5 5) Entrainement du modèle

```
Train on 52 samples
```

```
'{name:'count_25/Assign' id:5064 op device:{requested: '', assigned: ''} def:{{{node count_25/Assign}} = AssignVariableOp[_has_manual_control_dependencies=true, dtype=DT_FLOAT, validate_shape=false](count_25, count_25/Initializer/zeros)}}' was changed by setting attribute after it was run by a session. This mutation will have no effect, and will trigger an error in the future. Either don't modify nodes after running them or create a new session.
```

```
mean_squared_error: 0.0069
Epoch 3/100
52/52 [============ ] - Os 2ms/sample - loss: 0.0068 -
mean_squared_error: 0.0068
Epoch 4/100
mean squared error: 0.0069
Epoch 5/100
mean_squared_error: 0.0069
Epoch 6/100
mean_squared_error: 0.0072
Epoch 7/100
mean_squared_error: 0.0071
Epoch 8/100
mean_squared_error: 0.0067
Epoch 9/100
mean_squared_error: 0.0067
Epoch 10/100
mean_squared_error: 0.0068
Epoch 11/100
52/52 [============= ] - Os 595us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 12/100
mean_squared_error: 0.0068
Epoch 13/100
52/52 [============= ] - Os 699us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 14/100
mean_squared_error: 0.0067
Epoch 15/100
mean_squared_error: 0.0069
Epoch 16/100
mean_squared_error: 0.0069
Epoch 17/100
mean_squared_error: 0.0068
Epoch 18/100
```

```
mean_squared_error: 0.0069
Epoch 19/100
52/52 [============= ] - Os 534us/sample - loss: 0.0068 -
mean_squared_error: 0.0068
Epoch 20/100
mean_squared_error: 0.0067
Epoch 21/100
mean_squared_error: 0.0066
Epoch 22/100
52/52 [============= ] - Os 703us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 23/100
mean_squared_error: 0.0068
Epoch 24/100
mean_squared_error: 0.0068
Epoch 25/100
mean_squared_error: 0.0069
Epoch 26/100
mean_squared_error: 0.0068
Epoch 27/100
52/52 [============= ] - Os 706us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 28/100
mean_squared_error: 0.0067
Epoch 29/100
52/52 [============== ] - Os 729us/sample - loss: 0.0068 -
mean_squared_error: 0.0068
Epoch 30/100
mean_squared_error: 0.0067
Epoch 31/100
mean_squared_error: 0.0067
Epoch 32/100
52/52 [============= ] - Os 583us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 33/100
mean_squared_error: 0.0067
Epoch 34/100
52/52 [========== ] - Os 521us/sample - loss: 0.0067 -
```

```
mean_squared_error: 0.0067
Epoch 35/100
52/52 [============= ] - Os 320us/sample - loss: 0.0066 -
mean_squared_error: 0.0066
Epoch 36/100
mean_squared_error: 0.0067
Epoch 37/100
mean_squared_error: 0.0066
Epoch 38/100
mean_squared_error: 0.0066
Epoch 39/100
mean_squared_error: 0.0066
Epoch 40/100
mean_squared_error: 0.0067
Epoch 41/100
mean_squared_error: 0.0068
Epoch 42/100
mean_squared_error: 0.0068
Epoch 43/100
mean_squared_error: 0.0068
Epoch 44/100
mean_squared_error: 0.0068
Epoch 45/100
mean_squared_error: 0.0067
Epoch 46/100
mean_squared_error: 0.0068
Epoch 47/100
mean_squared_error: 0.0067
Epoch 48/100
52/52 [============ ] - Os 580us/sample - loss: 0.0069 -
mean_squared_error: 0.0069
Epoch 49/100
52/52 [============ ] - Os 429us/sample - loss: 0.0071 -
mean_squared_error: 0.0071
Epoch 50/100
```

```
mean_squared_error: 0.0069
Epoch 51/100
52/52 [============== ] - Os 442us/sample - loss: 0.0070 -
mean_squared_error: 0.0070
Epoch 52/100
mean_squared_error: 0.0067
Epoch 53/100
mean_squared_error: 0.0067
Epoch 54/100
mean_squared_error: 0.0068
Epoch 55/100
mean_squared_error: 0.0067
Epoch 56/100
52/52 [============= ] - Os 340us/sample - loss: 0.0066 -
mean_squared_error: 0.0066
Epoch 57/100
mean_squared_error: 0.0066
Epoch 58/100
mean_squared_error: 0.0066
Epoch 59/100
52/52 [============== ] - Os 479us/sample - loss: 0.0066 -
mean_squared_error: 0.0066
Epoch 60/100
mean_squared_error: 0.0066
Epoch 61/100
52/52 [============== ] - Os 792us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 62/100
mean_squared_error: 0.0066
Epoch 63/100
mean_squared_error: 0.0066
Epoch 64/100
52/52 [============= ] - Os 369us/sample - loss: 0.0068 -
mean_squared_error: 0.0068
Epoch 65/100
52/52 [============ ] - Os 434us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 66/100
52/52 [========= ] - Os 525us/sample - loss: 0.0072 -
```

```
mean_squared_error: 0.0072
Epoch 67/100
mean_squared_error: 0.0069
Epoch 68/100
mean squared error: 0.0070
Epoch 69/100
mean_squared_error: 0.0071
Epoch 70/100
mean_squared_error: 0.0070
Epoch 71/100
mean_squared_error: 0.0068
Epoch 72/100
52/52 [============== ] - Os 666us/sample - loss: 0.0068 -
mean_squared_error: 0.0068
Epoch 73/100
mean_squared_error: 0.0068
Epoch 74/100
mean_squared_error: 0.0067
Epoch 75/100
mean_squared_error: 0.0066
Epoch 76/100
52/52 [============ ] - Os 339us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 77/100
52/52 [============== ] - Os 278us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 78/100
mean_squared_error: 0.0067
Epoch 79/100
mean_squared_error: 0.0067
Epoch 80/100
52/52 [============== ] - Os 589us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 81/100
mean_squared_error: 0.0067
Epoch 82/100
```

```
mean_squared_error: 0.0068
Epoch 83/100
52/52 [============== ] - Os 636us/sample - loss: 0.0066 -
mean_squared_error: 0.0066
Epoch 84/100
mean squared error: 0.0067
Epoch 85/100
mean_squared_error: 0.0067
Epoch 86/100
52/52 [============= ] - Os 599us/sample - loss: 0.0067 -
mean_squared_error: 0.0067
Epoch 87/100
mean_squared_error: 0.0067
Epoch 88/100
mean_squared_error: 0.0066
Epoch 89/100
mean_squared_error: 0.0066
Epoch 90/100
mean_squared_error: 0.0066
Epoch 91/100
52/52 [============= ] - Os 729us/sample - loss: 0.0066 -
mean_squared_error: 0.0066
Epoch 92/100
52/52 [============ ] - Os 389us/sample - loss: 0.0066 -
mean_squared_error: 0.0066
Epoch 93/100
mean_squared_error: 0.0068
Epoch 94/100
mean_squared_error: 0.0067
Epoch 95/100
mean_squared_error: 0.0067
Epoch 96/100
52/52 [============== ] - Os 572us/sample - loss: 0.0072 -
mean_squared_error: 0.0072
Epoch 97/100
52/52 [============ ] - Os 685us/sample - loss: 0.0070 -
mean_squared_error: 0.0070
Epoch 98/100
52/52 [============ ] - Os 559us/sample - loss: 0.0068 -
```

[297]: <keras.callbacks.History at 0x7f9601e624c0>

L'entrainement peut être long et il faut au moins 100000 epochs pour avoir une approximation satisfaisante. On peut relancer à plusieurs reprise le fit() il repart de là ou le modèle était arrivé ce qui permet de suivre pas à pas l'evolution du loss. Au besoin avec keras il y a la possibilité de sauvegarder le modèle et de la recharger ensuite: https://www.tensorflow.org/guide/keras/save and serialize?hl=fr

```
[276]: mon_model.save('model_ventes-pneus')
```


WARNING:tensorflow:TensorFlow optimizers do not make it possible to access optimizer attributes or optimizer state after instantiation. As a result, we cannot save the optimizer as part of the model save file. You will have to compile your model again after loading it. Prefer using a Keras optimizer instead (see keras.io/optimizers).

Je me suis arrété aux valeurs suivantes loss: 0.0069 - mean\_squared\_error: 0.0069

```
[272]: ventes_pred=mon_model.predict(vente_pneus['numero_semaine_norm'].to_numpy())
```

2023-05-03 16:39:29.124880: W tensorflow/c/c\_api.cc:300] Operation '{name:'dense\_20/Sigmoid' id:2310 op device:{requested: '', assigned: ''} def:{{{node dense\_20/Sigmoid}} = Sigmoid[T=DT\_FLOAT, \_has\_manual\_control\_dependencies=true](dense\_20/BiasAdd)}}' was changed by setting attribute after it was run by a session. This mutation will have no effect, and will trigger an error in the future. Either don't modify nodes after running them or create a new session.

[274]: [<matplotlib.lines.Line2D at 0x7f9601bfaa30>]




Biensur pour revenir aux valeurs réelles il faudrait faire

```
[292]: pred=[]
  for i in range(1,53,1):
        pred.append(moy.max()*mon_model.predict(np.array([[i/52]]))[0][0])

[294]: import numpy as np
  listOf_Xticks = np.arange(0, 52, 4)
  plt.xticks(listOf_Xticks)
  plt.scatter(vente_pneus['numero semaine'],vente_pneus['moy'],marker='+')
  plt.plot(vente_pneus['numero semaine'],pred,color='blue')
```

[294]: [<matplotlib.lines.Line2D at 0x7f9601847ac0>]



[]: